

RDC News Intelligence — Résultats et corpus multilingue

Résultats et discussion — RDC News Intelligence

- Introduction
- 1. Objectifs de l'évaluation
- 2. Méthodologie
- 3. Résultats
- 4. Discussion
- 5. Perspectives (après soutenance)

Annexe A — Récupérer les chiffres du corpus (5 minutes)

Annexe B — Comment chercher des sites d'articles en swahili (RDC / région)

Annexe C — Paragraphe prêt à coller dans l'article (Discussion)

Documents associés

Sources swahili et anglaises — corpus RDC News Intelligence

- 1. Synthèse du corpus (après rééquilibrage)
- 2. Sources swahili intégrées
- 3. Sources anglaises (ajouts récents)
- 4. Sources écartées ou retirées du catalogue
- 5. Pistes d'enrichissement

Résultats et discussion — RDC News Intelligence

Attribut	Valeur
Document	Article_Resultats_et_Discussion
Usage	Chapitre / article « Résultats et discussion » du mémoire
Version	1.2 (mai 2026)
Liens	Ch.2 README_CHAPITRE_2.md ·
	Ch.3
	Chapitre_3_Modelisation.md ·
	Ch.4
	Chapitre_4_Deploiement.md

Introduction

Ce chapitre présente les **résultats** obtenus avec le prototype RDC News Intelligence : constitution du corpus, comportement du pipeline RAG, exploitation via WhatsApp, et premiers essais multilingues (français, anglais, swahili). Les mesures du §3.1 et les tests du §3.4 ont été réalisés sur l’environnement de développement (PostgreSQL, ChromaDB, Ollama `mistral:7b-instruct-v0.3-q4_K_M`). L’extension du corpus swahili est documentée dans `SOURCES_SWAHILI_AUDIT.md`.

1. Objectifs de l’évaluation

L’évaluation vise à répondre à trois questions, alignées sur le cahier des charges du TFC :

- 1. **Couverture factuelle** — Le corpus indexé permet-il de sourcer des vérifications sur l’actualité RDC ?
- 2. **Qualité des réponses** — Les verdicts (VRAI, FAUX, IMPRÉCIS, NON VÉRIFIABLE) sont-ils **ancrés dans les articles récupérés**, sans invention manifeste ?
- 3. **Accessibilité multilingue** — Jusqu’où le système accepte des requêtes en **français, anglais et swahili** compte tenu du corpus actuel (majoritairement francophone) ?

Périmètre : backend ai-service, déploiement VPS, canal WhatsApp (Whapi) et optionnellement `POST /rag` (web). Pas de benchmark académique à grande échelle (pas de jeu de données gold standard annoté) : il s’agit d’une **évaluation de prototype** reproductible.

2. Méthodologie

2.1 Indicateurs retenus

Indicateur	Définition	Source
N articles PostgreSQL	Nombre de lignes articles	GET /admin/overview
N vecteurs Chroma	Documents dans la collection articles_rdc	idem (embedded_articles)
Couverture embedding	$\text{embedded} / \text{total} \times 100$	idem
Sources actives	Médias avec au moins 1 article indexé	sources_breakdown
Catalogue configuré	sources.json (sources avec ≥ 1 article)	51 sourceId actifs
Articles swahili	Cinq flux sourceLang=sw	167 articles ($\approx 1,3\%$)

Articles anglais	Flux sourceLang=en	642 articles (≈ 4,9 %)
Top-K retrieval	Articles passés au LLM après similarité cosinus	WHATSAPP_TOP_K / RAG_WEB_TOP_K (défaut 3)
Seuil similarité messagerie	Filtre minimal avant génération	RAG_MIN_SIMILARITY_MSG = 0,40
Latence bout-en-bout	Réception webhook → envoi réponse Whapi	Logs [HTTP] + traces RAG/LLM
Distribution des verdicts	Comptage manuel sur échantillon de tests	Grille §3.4

2.2 Modèles et paramètres (référence reproductible)

Composant	Technologie
Embeddings	sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2 (384 dim., cosine)
Vector store	ChromaDB, collection articles_rdc
Génération	Mistral via Ollama (OLLAMA_MODEL, contexte OLLAMA_NUM_CTX 2048)
OCR images	Tesseract (OCR_LANG défaut fra+eng)
Re-ranking	Optionnel (RAG_ENABLE_RERANK=true)

2.3 Protocole de tests manuels

Pour chaque ligne du tableau §3.4 :

1. Formuler une **affirmation** ou une **question** (copier-coller possible depuis un groupe WhatsApp réel, anonymisé).
2. Envoyer via **WhatsApp privé** (Topic Gate désactivé) ou POST /rag avec le même texte.
3. Noter le **verdict** affiché, le nombre de **sources** citées, et si la réponse cite des médias **RDC** pertinents.
4. Classer le résultat : **satisfaisant** / **partiel** / **échec** (NON VÉRIFIABLE attendu si sujet absent du corpus).

Recommandation : au minimum **5 requêtes FR** (sujets couverts par Radio Okapi / Actualité.cd), **3 EN**, **3 SW** — pour montrer l'écart corpus / interface.

3. Résultats

3.1 Corpus et indexation

Indicateur	Valeur mesurée	Commentaire
Articles PostgreSQL		

	13 163	Snapshot mai 2026
Articles embeddés (Chroma)	13 163	Aligné sur PostgreSQL (sync_to_chroma.py)
Couverture embedding (%)	100 %	
Sources distinctes en base	~40	Médias ayant au moins un article
Catalogue sources.json	51 entrées	17 sources FR vides retirées ; +5 EN, +1 SW (RFI)
Articles swahili indexés	167	bbc-sw 48 · voa 42 · dw-kiswahili 40 · rfi-sw 24 · dw-congo 13
Articles anglais indexés	642	bbc-world 240 · guardian 111 · dw-world 65 · voa 60 · ...
Articles sans source_id	0	Métadonnées sources complètes
Top 3 médias par volume	1. lesvolcansnews.net (1 833) 2. rfi.fr (1 784) 3. mediacongo.net (1 634)	Puis 7sur7.cd, france24.com, radiokapi.net

Interprétation : le corpus reste **majoritairement francophone** (~94 %), avec un **volet anglais** désormais significatif (**642** articles, flux BBC/Guardian/VOA/DW) et un **volet swahili** en croissance (**167** articles, cinq flux). Le nettoyage du catalogue évite de crawler des médias FR qui ne produisaient aucun document indexé.

3.2 Comportement du pipeline RAG

Étape	Observation typique
Embedding requête	Logs Batches : 100% (SentenceTransformers) — quelques centaines de ms
Retrieval Chroma	Jusqu'à 9 candidats internes ; filtrage au seuil 0,40 en messagerie
Re-ranking LLM	Améliore l'ordre des 3 articles retenus ; coût temps supplémentaire
Génération Mistral	Goulot principal : 5 à 7 min par requête en test local (CPU, RAG_ENABLE_RERANK=false)
Verdict structuré	Format fixe : □ VÉRIFICATION + □ EXPLICATION + □ SOURCES
Absence de sources	Message NON VÉRIFIABLE sans hallucination de faits (comportement voulu)

3.3 Canal WhatsApp et robustesse

Aspect	Résultat
Vérification 1:1	Fonctionnelle ; Topic Gate désactivé hors groupe
Vérification groupe	Topic Gate limite le bruit (politique, sport, santé, conflit RDC)
Images	OCR fra+eng puis même pipeline RAG
Déploiement VPS	File locale 127.0.0.1:8000 (queue pop + reply relay) évite timeouts HTTPS publics
Incident corrigé	Envoi bloqué par argument wa_message_id invalide sur _send_whatsapp_text — corrigé (marquage « lu » + typing séparé)

3.4 Grille d’essais manuels (RAG in-process, mai 2026)

Protocole : RAGService.generate_answer_stream, top_k=3, channel=web, RAG_ENABLE_RERANK=false, modèle Ollama mistral:7b-instruct-v0.3-q4_K_M. Fichier brut : data/evaluation/rag_manual_tests.json.

ID	Langue	Requête (résumé)	Verdict	Latence	Sources	Appréciation
T1	FR	RDC 20 M\$ contre Ebola 2026	VRAI	~7 min	3	Satisfaisant — ancré corpus FR (7sur7, etc.)
T2	FR	Kyabula démission Haut-Katanga	<i>(non rejoué)</i>	—	—	Sujet présent dans le corpus (7sur7.cd crawlé)
T3	FR	Président FR gagne rugby 2026	FAUX	~6 min	3	Satisfaisant — rejet d’une affirmation hors faits
T4	EN	DRC Ebola funds 2026	IMPRÉCIS	~6,5 min	3	Satisfaisant — cross-lingue, preuves surtout FR
T5	EN	Nobel physique Kinshasa (hors sujet)	<i>(non rejoué)</i>	—	—	NON VÉRIFIABLE attendu

T6	SW	Fedha DRC Ebola 2026	IMPRÉCIS	~7 min	3 (FR)	Partiel — réponse en SW mais sources FR dominantes
T7	SW	Kyabula gavana Haut- Katanga ?	IMPRÉCIS	~5 min	3 (FR)	Partiel — même limite corpus
T8	SW	Habari uchaguzi Congo	<i>(non rejoué)</i>	—	—	À compléter après crawl SW élargi

Note technique : les appels HTTP POST /rag ont renvoyé **500** lorsque l'API était saturée (crawl massif en parallèle) ; les tests ci-dessus ont été validés **en direct** sur le service Python.

Synthèse des résultats :

En **français**, le RAG produit des verdicts **VRAI / FAUX / IMPRÉCIS** cohérents avec les articles indexés. En **anglais**, le corpus dédié (642 articles) améliore le ancrage des réponses, tout en restant complété par l'embedding cross-langue vers le français. En **swahili** (167 articles), le retrieval commence à citer VOA/BBC/DW/RFI SW ; les verdicts peuvent rester **IMPRÉCIS** lorsque le sujet n'est couvert que par des sources FR — voir [SOURCES_SWAHILI_AUDIT.md](#).

3.5 Distribution des verdicts (échantillon tests §3.4)

Sur 5 requêtes exécutées :

Verdict	Nombre	%
VRAI	1	20 %
FAUX	1	20 %
IMPRÉCIS	3	60 %
NON VÉRIFIABLE	0	0 %

4. Discussion

4.1 Atteinte des objectifs

Objectif « fact-checking ancré » — Le choix RAG + prompt strict (« **UNIQUEMENT** les articles fournis ») limite les inventions par rapport à un LLM nu. La limite principale n'est pas le modèle génératif mais la

couverture du corpus : un sujet viral non crawlé conduit systématiquement à NON VÉRIFIABLE, ce qui est **honnête** mais peut frustrer l'utilisateur.

Objectif « WhatsApp accessible » — Atteint sur le plan technique (webhook Whapi, file, réponses longues découpées). La **latence** (Ollama CPU) reste un facteur d'expérience utilisateur ; un message « Analyse en cours... » atténue l'attente.

Objectif « multilingue (FR, EN, SW) » — À présenter en **trois niveaux** (recommandation pour la soutenance) :

Niveau	Français	Anglais	Swahili
L1 — Interface	Complet	Complet	Complet (requête comprise, réponse générée en SW possible)
L2 — Preuves (corpus)	Fort	Partiel (articles FR/EN internationaux)	Faible aujourd'hui
L3 — Produit promis	Oui	Oui avec transparence	Non tant que sources SW non indexées

4.2 Multilinguisme : argument pour le mémoire

Le modèle d'embedding **multilingue** aligne requête et documents dans un même espace vectoriel : une question en anglais peut retrouver un article français pertinent (et inversement). Cela ne constitue pas une « traduction du corpus », mais une **recherche sémantique cross-lingue**.

Pour le swahili, la barrière reste **documentaire** mais réduite : **167** articles SW (**1,3 %**), cinq flux actifs. Pour l'anglais, **642** articles (**4,9 %**) permettent une **L2** plus solide qu'avec le seul cross-lingue. `habari.rdc.net` reste en **français** malgré le nom.

Position sur le multilinguisme : **FR** — L3 opérationnel ; **EN** — L2 solide, L3 partiel ; **SW** — L2 amorcé (objectif ≥ 500 articles SW pour L3).

4.3 Limites techniques

Limite	Impact	Piste
Corpus FR dominant ($\approx 99\%$)	SW encore minoritaire	<u>SOURCES_SWAHILI_AUDIT.md</u>
Historique couverture Chroma partielle	Risque de retrieval incomplet	python <code>scripts/sync_to_chroma.py</code> (résolu : 100 %) 20–30 paires (rumeur,

Pas de jeu de test annoté	Pas de précision / rappel chiffrés	verdict attendu) en travail futur
Topic Gate Telegram en privé	Plus strict que WhatsApp	Harmoniser <code>require_topic_gate</code> (évolution code)
Anti-surinformation M10	Regroupement doublons partiel (Redis)	§6.4 chapitre 2 — consolidation à compléter
OCR sans swa	Images swahili mal lues	<code>OCR_LANG=fra+eng+swa</code> après install pack tesseract

4.4 Comparaison avec l'état de l'art (narratif court)

Les chatbots généralistes répondent vite mais **sans garantie de source RDC**. RDC News Intelligence inverse le compromis : **latence plus élevée, traçabilité** (liens médias), verdicts catégorisés. C'est cohérent avec les exigences de lutte contre la désinformation en contexte **faible confiance médias / forte viralité WhatsApp**.

4.5 Éthique et responsabilité

- Le système **ne remplace pas** un journaliste : il agrège des articles déjà publiés.
- Le verdict IMPRÉCIS reflète des sources **contradictaires ou incomplètes**, pas une neutralité absolue.
- Les groupes WhatsApp : le bot ne supprime pas les messages tiers ; il limite surtout **ses propres** répétitions (objectif anti-surinformation).

5. Perspectives (après soutenance)

1. **Corpus swahili** — `crawl dw.com-sw-kiswahili` + volumes VOA/BBC ; colonne `articles.lang` (annexe B).
2. **Métriques formelles** — précision verdict vs annotateurs sur échantillon stratifié.
3. **GPU / modèle quantifié** — réduire latence Ollama sur VPS.
4. **Table verifications** — audit, statistiques automatiques pour un futur chapitre résultats quantitatif.

Annexe A — Récupérer les chiffres du corpus (5 minutes)

```
# API locale (adapter host si VPS)
curl -s http://127.0.0.1:8000/admin/overview | jq '.stats,
.top_sources[:5]'
```


Ou console admin frontend : page **Overview** (/admin).

Champs à recopier dans §3.1 :

- total_articles
- embedded_articles
- embedding_coverage
- total_sources
- top_sources

Requête SQL complémentaire (langue non stockée aujourd'hui) :

```
-- Le schéma actuel n'a pas de colonne lang ; comptage par source  
uniquement  
SELECT COALESCE(source_id, 'unknown') AS source, COUNT(*) AS n  
FROM articles  
GROUP BY source  
ORDER BY n DESC  
LIMIT 15;
```

Annexe B — Comment chercher des sites d'articles en swahili (RDC / région)

Objectif : identifier des **sources crawlables** (HTML, WordPress, RSS) dont le **corps d'article** est rédigé en kiswahili, priorité **Est de la RDC, Katanga, groupements frontaliers, diaspora**.

B.1 Critères de sélection (checklist)

Critère	Pourquoi
Langue principale = sw	Sinon le RAG n'apporte pas de preuves SW
Actualité RDC / Grands Lacs	Alignement mission projet
RSS ou WordPress	Déjà supportés par le crawler (sourceKind)
Licence / accès public	Éviter paywalls sans accord
Volume ≥ quelques articles / semaine	Justifier l'indexation
Stabilité HTML	Sélecteurs CSS reproductibles (comme sources.json)

B.2 Pistes de recherche (mots-clés et requêtes)

Canal	Exemple
Google	habari congo swahili, gazeti congo swahili, habari za congo leo sauti ya congo swahili, ukurasa wa

Google	habari congo
Répertoires médias	MediaCloud , Mondoblog (filtre RDC / sw)
ONG / UN	UNICEF, MONUSCO, OCHA — pages kiswahili sur la RDC
Radios	Radios communautaires Est (Goma, Bukavu, Uvira) — sites avec archive texte

B.3 Statut des candidats (audit mai 2026)

Source	Statut	sourceId
VOA Swahili	✓ Intégré, crawl OK	voaswahili.com
BBC News Swahili	✓ Intégré (RSS)	bbc.com-swahili
DW — Congo	✓ Intégré	dw.com-sw-congo
DW — Kiswahili	⌘ Configuré, crawl à lancer	dw.com-sw-kiswahili
habarirdc.net	✗ Français (lang=fr-FR)	déjà catalogue
bukavufm.com	⚠ Contenu faible / placeholder	déjà catalogue
Radio Okapi /sw	✗ RSS 410 Gone	—

Détail complet : [SOURCES_SWAHILI_AUDIT.md](#).

B.4 Procédure technique d'intégration (quand une source est validée)

1. **Test manuel** — 5 URLs d'articles SW, copier titre + extrait.
2. **Test sémantique** — POST /rag avec requête SW sur le sujet ; noter si NON VÉRIFIABLE.
3. **Entrée sources.json** — copier un bloc wordpress ou html existant ; renseigner sourceId unique (ex. voaswahili.com).
4. **Crawl pilote** — `python -m app.services.crawler.scripts.sync --source-id <id> --limit 20`
5. **Sync Chroma** — `python scripts/sync_to_chroma.py` (ou pipeline admin).
6. **Re-test** — rejouer T6–T8 du tableau §3.4.

Évolution schéma (recommandée) : colonne `articles.lang` (fr | en | sw)
+ filtre `retrieval where lang=sw` pour ne pas mélanger les preuves.

B.5 Indicateurs de succès corpus swahili

Indicateur	Cible indicative
------------	------------------

Articles lang=sw indexés	≥ 500 (pilote) puis ≥ 2 000
Part SW dans Chroma	≥ 10 % du corpus total
Tests T6–T8	≥ 2/3 « satisfaisant » avec sources SW citées
OCR	Pack tesseract-ocr-swa + OCR_LANG mis à jour

Annexe C — Paragraphe prêt à coller dans l'article (Discussion)

Les résultats confirment la faisabilité d'un assistant de vérification sur WhatsApp fondé sur un corpus journalistique indexé en base vectorielle. En conditions réelles (VPS, Whapi, Ollama local), le pipeline enchaîne réception, recherche sémantique et génération de verdicts structurés, avec refus explicite de répondre lorsque aucune source locale n'est trouvée. La performance perçue est dominée par le temps de génération du LLM ; la qualité factuelle dépend avant tout de l'étendue du corpus. Le multilinguisme illustre une distinction importante : l'interface et l'embedding multilingue permettent des requêtes en anglais et en swahili, mais la **valeur probatoire** reste liée aux langues effectivement présentes dans la base — aujourd'hui le français. L'extension vers un corpus swahili, alimenté par des médias de l'Est de la RDC et des radios régionales, constitue la priorité scientifique et opérationnelle pour honorer la promesse trilingue au-delà de la démonstration technique.

Documents associés

Document	Contenu
Chapitre_4_Deploiement.md §10	Tableau FR / EN / SW déploiement
BROUILLON_ANTI_SURINFORMATION_WHATSAPP.md	Pistes anti-submersion
SOURCES_SWAHILI_AUDIT.md	Audit et commandes crawl SW
<code>data/crawler/sources.json</code>	Catalogue (64 sources, dont 4 SW)
<code>data/evaluation/rag_manual_tests.json</code>	Résultats bruts des tests RAG

Fin du chapitre — Résultats et discussion (v1.2).

Sources swahili et anglaises — corpus RDC News Intelligence

Date | 2026-05-26 |
Objectif | Constituer un corpus multilingue (FR majoritaire, EN et SW en extension) |

1. Synthèse du corpus (après rééquilibrage)

Langue	Articles	Part du corpus	Sources actives (catalogue sourceLang)
Français	~12 350	~94 %	Médias RDC + RFI, France 24, etc.
Anglais	642	~4,9 %	BBC world/africa, Guardian, VOA, DW, WHO, etc.
Swahili	167	~1,3 %	VOA SW, BBC SW, DW SW×2, RFI SW
Total	13 163	100 %	Chroma aligné (100 % couverture)

Le catalogue sources.json a été **nettoyé** : 17 entrées francophones sans aucun article en base ont été retirées ; 5 flux anglais et 1 flux swahili (RFI) ont été ajoutés.

2. Sources swahili intégrées

sourceId	URL / flux	Articles (approx.)
bbc.com-swahili	RSS feeds.bbc.co.uk/swahili	48
voaswahili.com	Page d'accueil /a/*.html	42
dw.com-sw-kiswahili	Rubrique Kiswahili DW	40
rfi.fr-swahili	RSS rfi.fr/sw/rss	24
dw.com-sw-congo	Section RDC (SW)	13

Commandes crawl :

```
cd ai-service && source venv/bin/activate
for s in voaswahili.com bbc.com-swahili dw.com-sw-congo dw.com-sw-
kiswahili rfi.fr-swahili; do
    python -m app.services.crawler.scripts.sync --source-id "$s" --
limit 80
done
```

3. Sources anglaises (ajouts récents)

sourceId	Flux	Articles (approx.)
bbc.com-africa-en	BBC Africa RSS	23+

theguardian.com-africa-en	Guardian /world/africa/rss	20+
dw.com-en-africa	DW English Africa	5+
(existants, sourceLang: en)	bbc-world, theguardian.com, voanews.com, dw.com-world, ...	voir admin

4. Sources écartées ou retirées du catalogue

Cas	Exemple
0 article en BDD	actualite.cd, tflinfo.fr, lemonde.fr, ... (17 retirées)
Nom « Habari » mais FR	habarirdc.net (conservé, langue française)
RSS indisponible	Radio Okapi /sw (410)
Crawl ONG sans corps	un.org-africa-en (retiré si 0 article après test)

Rééquilibrage automatique :

```
python scripts/rebalance_sources_catalog.py
```

5. Pistes d'enrichissement

- Porter `articles.lang` en base pour filtrer le retrieval par langue.
- Augmenter le volume SW (objectif **500+** articles) via crawl récurrent sur les 5 flux.
- OCR : `tesseract-ocr-swa` pour images WhatsApp en kiswahili.

Voir [*Article Resultats et Discussion.md*](#).