

RDC News Intelligence — Corpus anglais et swahili

Sources swahili et anglaises — corpus RDC News Intelligence

Date | 2026-05-26 |

Objectif | Constituer un corpus multilingue (FR majoritaire, EN et SW en extension) |

1. Synthèse du corpus (après rééquilibrage)

Langue	Articles	Part du corpus	Sources actives (catalogue sourceLang)
Français	~12 350	~94 %	Médias RDC + RFI, France 24, etc.
Anglais	642	~4,9 %	BBC world/africa, Guardian, VOA, DW, WHO, etc.
Swahili	167	~1,3 %	VOA SW, BBC SW, DW SW×2, RFI SW
Total	13 163	100 %	Chroma aligné (100 % couverture)

Le catalogue sources.json a été **nettoyé** : 17 entrées francophones sans aucun article en base ont été retirées ; 5 flux anglais et 1 flux swahili (RFI) ont été ajoutés.

2. Sources swahili intégrées

sourceId	URL / flux	Articles (approx.)
bbc.com-swahili	RSS feeds.bbc.co.uk/swahili	48
voaswahili.com	Page d'accueil /a/*.html	42
dw.com-sw-kiswahili	Rubrique Kiswahili DW	40
rfi.fr-swahili	RSS rfi.fr/sw/rss	24
dw.com-sw-congo	Section RDC (SW)	13

Commandes crawl :

```
cd ai-service && source venv/bin/activate
for s in voaswahili.com bbc.com-swahili dw.com-sw-congo dw.com-sw-kiswahili rfi.fr-swahili; do
    python -m app.services.crawler.scripts.sync --source-id "$s" --
limit 80
```

3. Sources anglaises (ajouts récents)

sourceId	Flux	Articles (approx.)
bbc.com-africa-en	BBC Africa RSS	23+
theguardian.com-africa-en	Guardian /world/africa/rss	20+
dw.com-en-africa	DW English Africa	5+
(existants, sourceLang: en)	bbc-world, theguardian.com, voanews.com, dw.com-world, ...	voir admin

4. Sources écartées ou retirées du catalogue

Cas	Exemple
0 article en BDD	actualite.cd, tf1info.fr, lemonde.fr, ... (17 retirées)
Nom « Habari » mais FR	habarirdc.net (conservé, langue française)
RSS indisponible	Radio Okapi /sw (410)
Crawl ONG sans corps	un.org-africa-en (retiré si 0 article après test)

Rééquilibrage automatique :

```
python scripts/rebalance_sources_catalog.py
```

5. Pistes d'enrichissement

- Porter `articles.lang` en base pour filtrer le retrieval par langue.
- Augmenter le volume SW (objectif **500+** articles) via crawl récurrent sur les 5 flux.
- OCR : `tesseract-ocr-swa` pour images WhatsApp en kiswahili.

Voir [*Article_Resultats_et_Discussion.md*](#).